DataCo Smart Supply Chain –
Dự đoán rủi ro giao hàng trễ

Mục lục

1 Giới thiệu bài toán và dữ liệu **2**

2 Lựa chọn hướng tiếp cận: Binary hay Multiclass **2**

3 Tổng quan và chất lượng dữ liệu **3**

3.1 Giá trị thiếu 3

3.2 Trùng lặp và các cột không có thông tin 3

4 Phân tích rò rỉ dữ liệu (data leakage) **3**

5 Phân tích khám phá dữ liệu (EDA) **5**

5.1 Yếu tố vận chuyển 5

5.2 Yếu tố địa lý 6

5.3 Sản phẩm và khách hàng 8

5.4 Biến số và tương quan 9

6 Tiền xử lý dữ liệu **11**

7 Kết luận, hạn chế và hướng phát triển **11**

Phụ lục: Danh sách file minh chứng **13**

1. Giới thiệu bài toán và dữ liệu

Bộ dữ liệu **DataCo Smart Supply Chain** ghi lại các giao dịch bán hàng của công ty DataCo Global trong giai đoạn **01/2015 – 01/2018**. Mỗi dòng là một **sản phẩm (item) trong một đơn hàng**, kèm thông tin khách hàng, sản phẩm, thị trường, phương thức vận chuyển và kết quả giao hàng.

Mục tiêu: xây dựng mô hình dự đoán **đơn hàng có bị giao trễ hay không** ngay tại thời điểm đặt hàng, để doanh nghiệp có thể chủ động đổi phương thức vận chuyển hoặc thông báo trước cho khách hàng.

Bảng 1: Thông tin tổng quan bộ dữ liệu

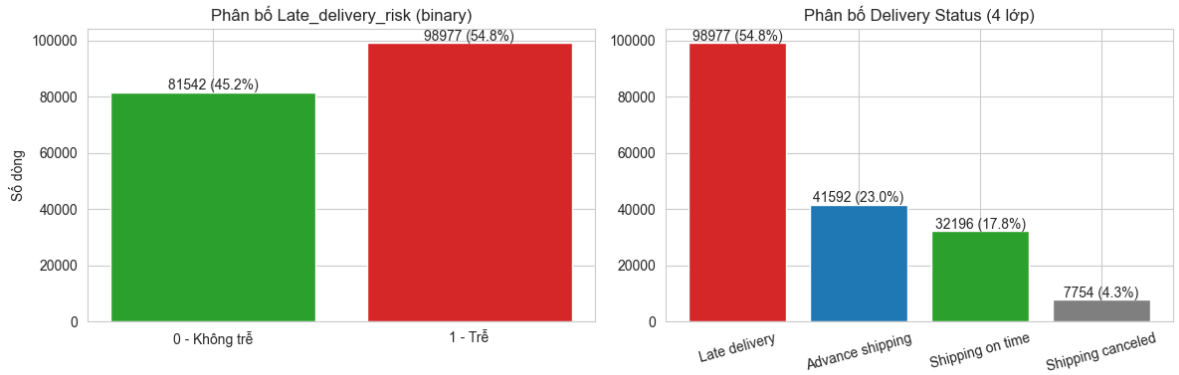
Thông tin	Giá trị
File dữ liệu	DataCoSupplyChainDataset.csv (~91,5 MB, encoding latin-1)
File mô tả cột	DescriptionDataCoSupplyChain.csv
Số dòng	180.519 (mỗi dòng là 1 order item, Order Item Id duy nhất)
Số đơn hàng khác nhau (Order Id)	65.752
Số cột	53 (24 object, 15 float64, 14 int64)
Thời gian đặt hàng	01/01/2015 – 31/01/2018

2. Lựa chọn hướng tiếp cận: Binary hay Multiclass

Dựa vào file mô tả, có 3 cột có thể dùng làm biến mục tiêu:

Bảng 2: So sánh các lựa chọn biến mục tiêu

Cột	Loại	Phân bố	Đánh giá
Late_delivery_risk	Binary (2 lớp)	1 (trễ): 98.977 (54,8%) 0 (không trễ): 81.542 (45,2%)	**Chọn.** Cân bằng, ý nghĩa nghiệp vụ rõ ràng.
Delivery Status	Multiclass (4 lớp)	Late 54,8% · Advance 23,0% · On time 17,8% · Canceled 4,3%	Hướng mở rộng; lớp Canceled ít, cần xử lý mất cân bằng.
Order Status	Multiclass (9 lớp)	COMPLETE 33,0% … PAYMENT_REVIEW 1,0%	Không chọn. Là trạng thái xử lý đơn, không phải kết quả giao hàng.



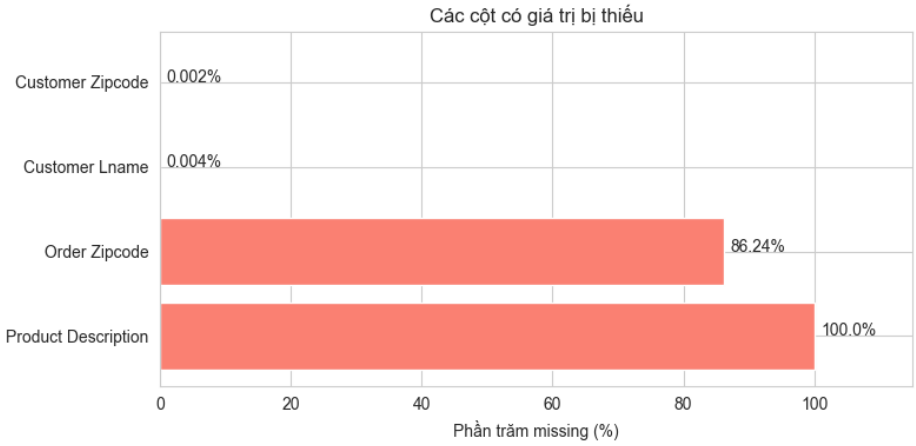
Hình 1: Phân bố của Late_delivery_risk (trái) và Delivery Status (phải). *(nguồn: figures/fig02_target.png)*

Kết luận: bài toán được xây dựng theo hướng **Binary Classification** với target Late_delivery_risk. Phân

tích ở mục 4 cho thấy Late_delivery_risk = 1 trùng 100% với Delivery Status = "Late delivery", tức nhãn binary là phiên bản gộp của nhãn 4 lớp (Late so với 3 lớp còn lại).

3. Tổng quan và chất lượng dữ liệu

3.1 Giá trị thiếu



Hình 2: Tỉ lệ giá trị thiếu theo cột. *(nguồn: figures/fig01_missing.png)*

- Product Description: thiếu 100% → bỏ.
- Order Zipcode: thiếu 86,24% (155.679 dòng) → bỏ.
- Customer Lname (8 dòng) và Customer Zipcode (3 dòng): thiếu rất ít và cũng bị loại ở bước tiền xử lý (cột định danh) nên không cần xử lý.

3.2 Trùng lặp và các cột không có thông tin

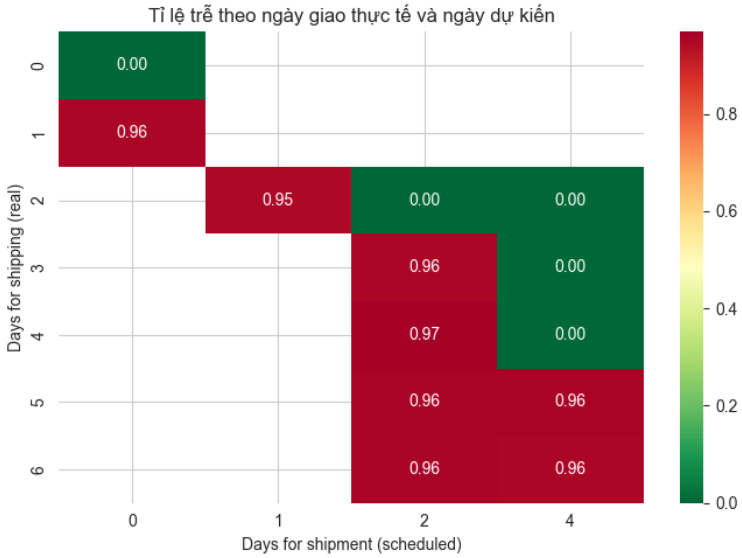
- Không có dòng trùng lặp (0 dòng).
- Customer Email, Customer Password chỉ có 1 giá trị "XXXXXXXXX" (đã bị che); Product Status chỉ có giá trị 0.
- Nhiều cặp cột **giống hệt nhau** (đã kiểm tra bằng code, kết quả đều True): Benefit per order = Order Profit Per Order; Sales per customer = Order Item Total; Product Price = Order Item Product Price; Order Customer Id = Customer Id; Category Id = Product Category Id; Product Card Id = Order Item Cardprod Id.
- Customer Country chỉ có 2 giá trị (EE. UU. và Puerto Rico): khách hàng và cửa hàng đều ở Mỹ, còn nơi giao hàng (Order Country) trải rộng 164 quốc gia.

4. Phân tích rò rỉ dữ liệu (data leakage)

Rò rỉ dữ liệu xảy ra khi một feature chứa thông tin chỉ biết được **sau khi** việc giao hàng đã diễn ra. Nếu dùng các cột này, mô hình sẽ có độ chính xác rất cao nhưng không dùng được trong thực tế.



Hình 3: Delivery Status so với Late_delivery_risk: trùng khớp hoàn toàn. *(nguồn: figures/fig03_leak_delivery_status.png)*



Hình 4: Tỉ lệ trễ theo số ngày giao thực tế (dòng) và số ngày giao dự kiến (cột). *(nguồn: figures/fig04_leak_real_vs_scheduled.png)*

- Delivery Status = "Late delivery" ⇔ Late_delivery_risk = 1 (98.977 dòng), các trạng thái còn lại đều = 0.
- Chỉ cần luật Days for shipping (real) > Days for shipment (scheduled) đã đúng **97,55%** (176.096 trên 180.519 dòng). 4.423 dòng không khớp đều thuộc nhóm "Shipping canceled".
- Order Status: CANCELED (3.692) + SUSPECTED_FRAUD (4.062) = đúng 7.754 dòng "Shipping canceled", là thông tin sau xử lý đơn.
- shipping date (DateOrders): ngày giao thực tế, suy ra trực tiếp số ngày giao thực tế.

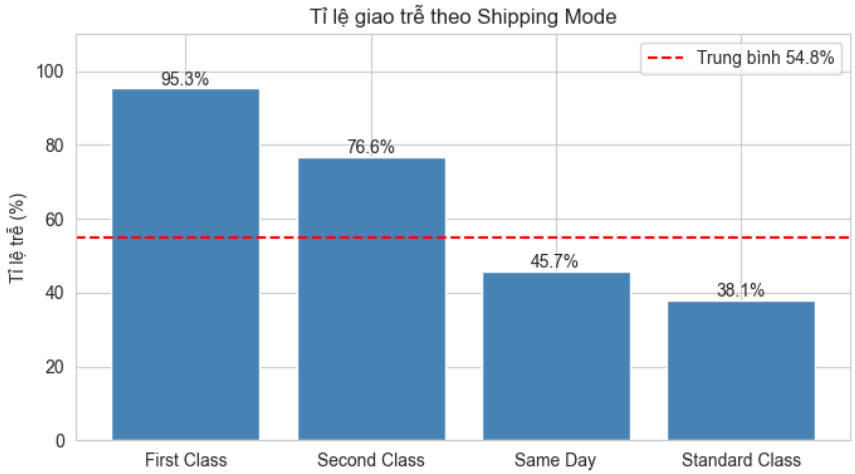
⇒ Loại bỏ 4 cột leakage: Delivery Status, Days for shipping (real), shipping date (DateOrders), Order Status. Minh chứng: notebook mục 4.

5. Phân tích khám phá dữ liệu (EDA)

Với các biến phân loại, báo cáo dùng **tỉ lệ đơn trễ (%)** của từng nhóm và so sánh với tỉ lệ trễ trung bình của toàn bộ dữ liệu là **54,83%** (đường nét đứt màu đỏ trên biểu đồ).

Ghi chú: phần EDA theo thời gian (ngày/giờ đặt hàng) tạm thời chưa đưa vào báo cáo này, sẽ được nghiên cứu và bổ sung ở lần nộp sau.

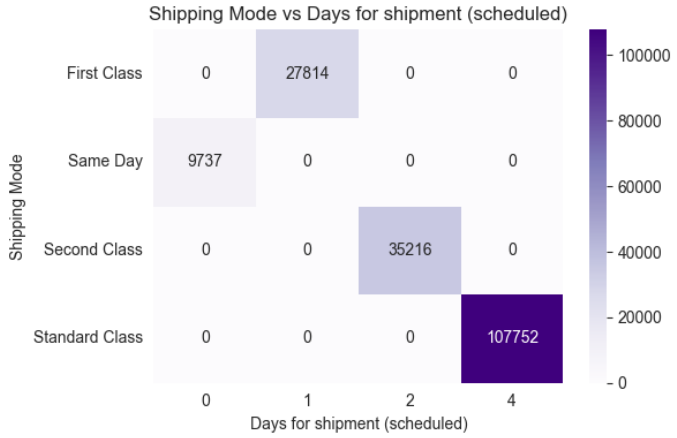
5.1 Yếu tố vận chuyển



Hình 5: Tỉ lệ giao trễ theo Shipping Mode. *(nguồn: figures/fig05_late_by_shipping_mode.png)*

Bảng 3: Tỉ lệ trễ theo phương thức vận chuyển

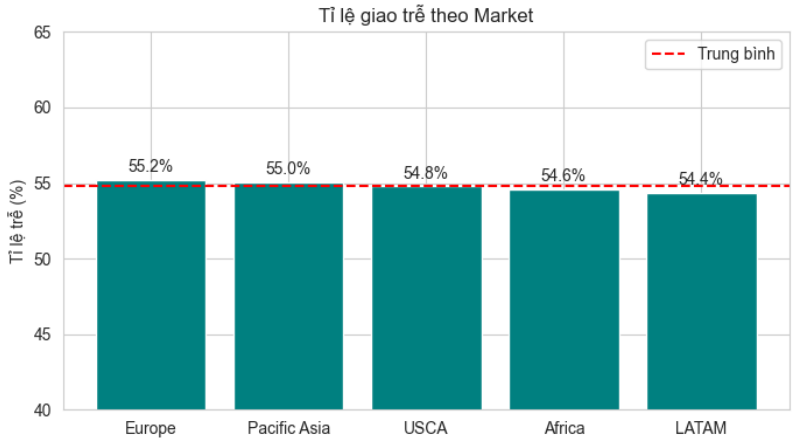
Shipping Mode	Số ngày dự kiến	Số dòng	Tỉ lệ trễ
First Class	1	27.814	95,32%
Second Class	2	35.216	76,63%
Same Day	0	9.737	45,74%
Standard Class	4	107.752	38,07%



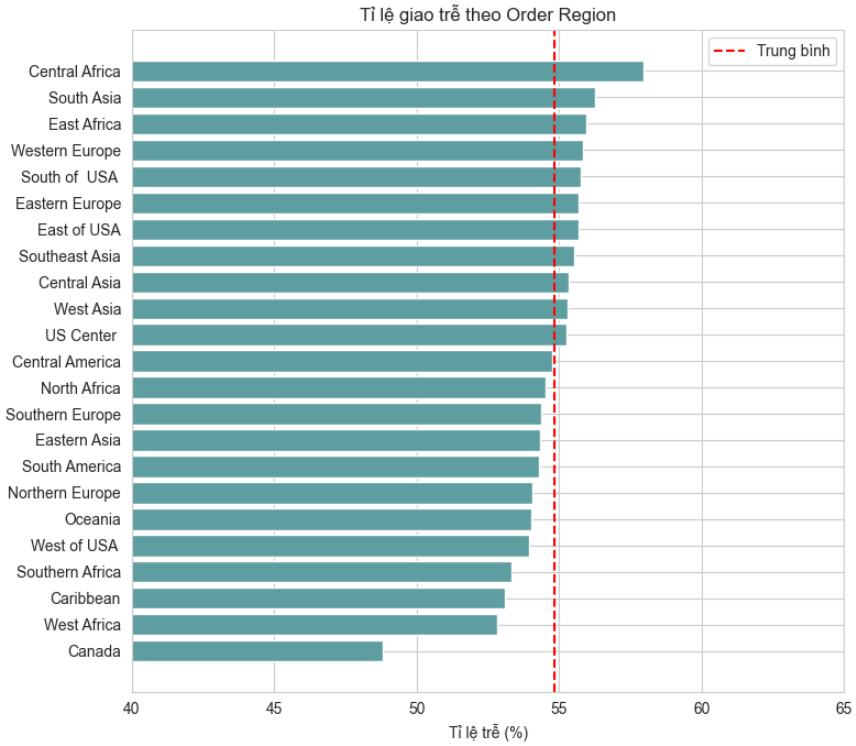
Hình 6: Mỗi Shipping Mode ứng với đúng một giá trị Days for shipment (scheduled). *(nguồn: figures/fig07_shipping_mode_vs_scheduled.png)*

- Shipping Mode là yếu tố phân biệt mạnh nhất: First Class trễ tới 95,3% trong khi Standard Class chỉ 38,1%.
- Mỗi Shipping Mode gắn với đúng 1 giá trị số ngày dự kiến (First = 1, Second = 2, Same Day = 0, Standard = 4), nên hai cột mang cùng một thông tin. Vì vậy biểu đồ tỉ lệ trễ theo số ngày dự kiến (file fig06 trong thư mục figures/) giống hệt biểu đồ Shipping Mode ở trên.
- Diễn giải: các lựa chọn giao nhanh có lịch hẹn quá gấp so với khả năng thực tế nên rất hay bị trễ.

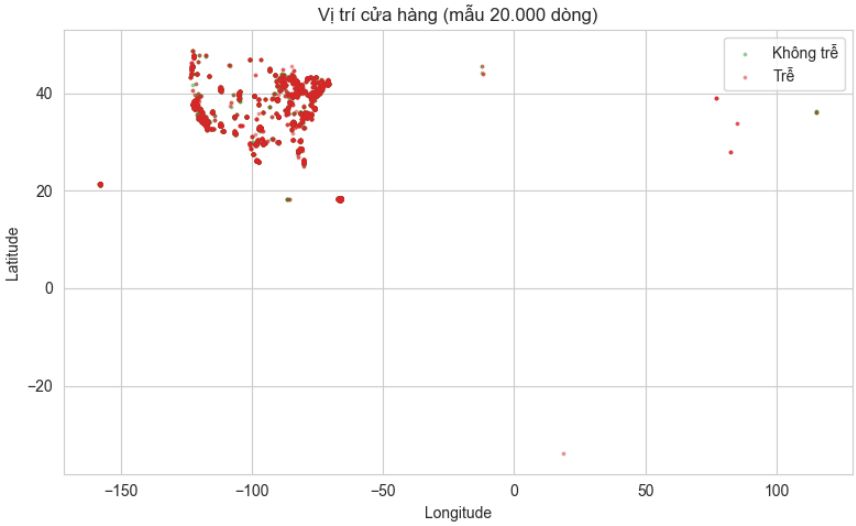
5.2 Yếu tố địa lý



Hình 7: Tỉ lệ giao trễ theo Market. *(nguồn: figures/fig08_late_by_market.png)*



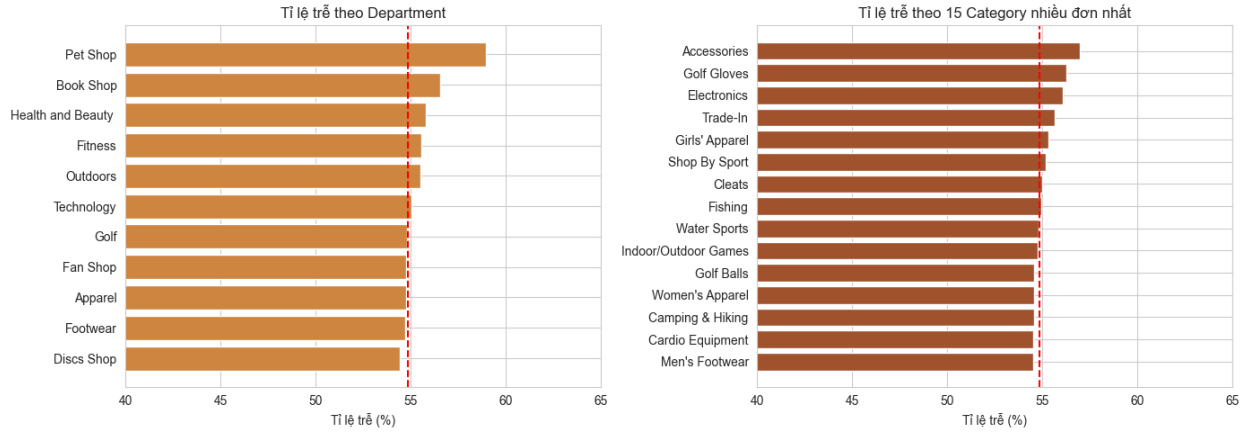
Hình 8: Tỉ lệ giao trễ theo Order Region (23 vùng). *(nguồn: figures/fig09_late_by_region.png)*



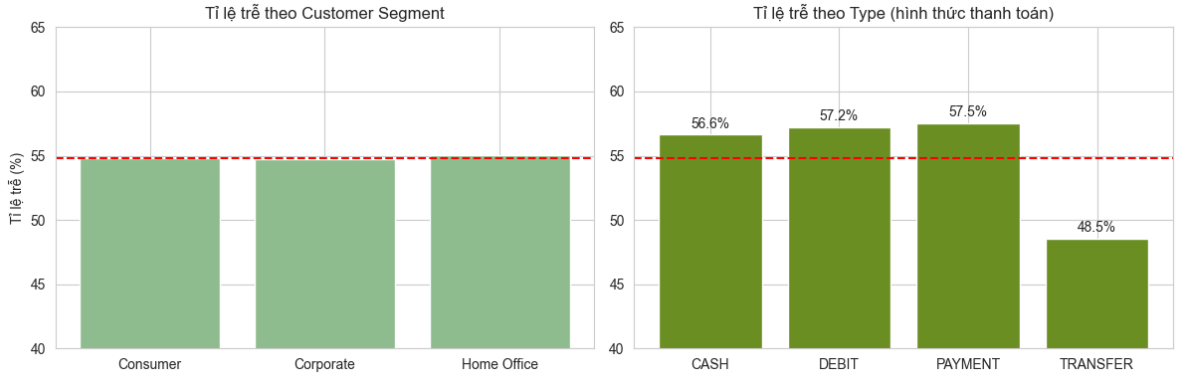
Hình 9: Vị trí cửa hàng (Latitude/Longitude), mẫu 20.000 dòng, tô màu theo target. *(nguồn: figures/fig10_store_location.png)*

- Market: tỉ lệ trễ chỉ từ 54,4% (LATAM) đến 55,2% (Europe), gần như không khác biệt.
- Order Region: từ 48,8% (Canada, chỉ 959 dòng) đến 58,0% (Central Africa, 1.677 dòng); phần lớn các vùng nằm trong khoảng 53–56%.
- Cửa hàng đều ở Mỹ/Puerto Rico, các điểm trễ và không trễ trộn lẫn nhau, nên vị trí cửa hàng không phân biệt rõ.
- ⇒ Yếu tố địa lý ảnh hưởng **yếu**.

5.3 Sản phẩm và khách hàng



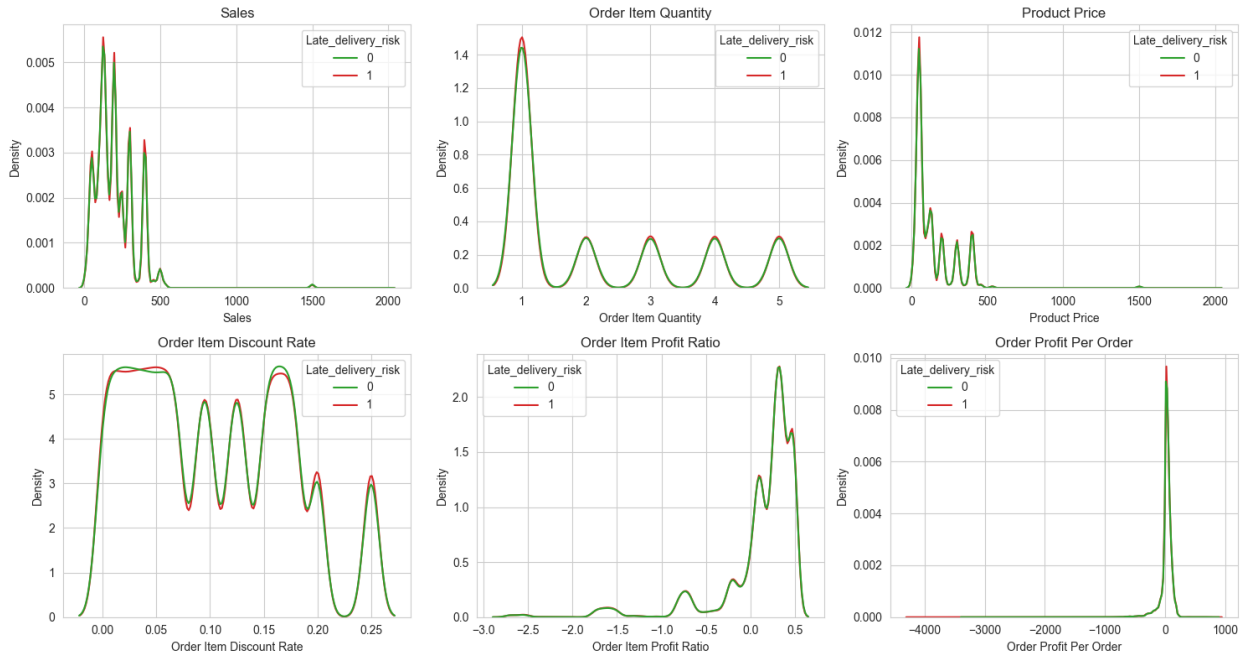
Hình 10: Tỉ lệ giao trễ theo Department và 15 Category nhiều đơn nhất. *(nguồn: figures/fig11_late_by_product.png)*



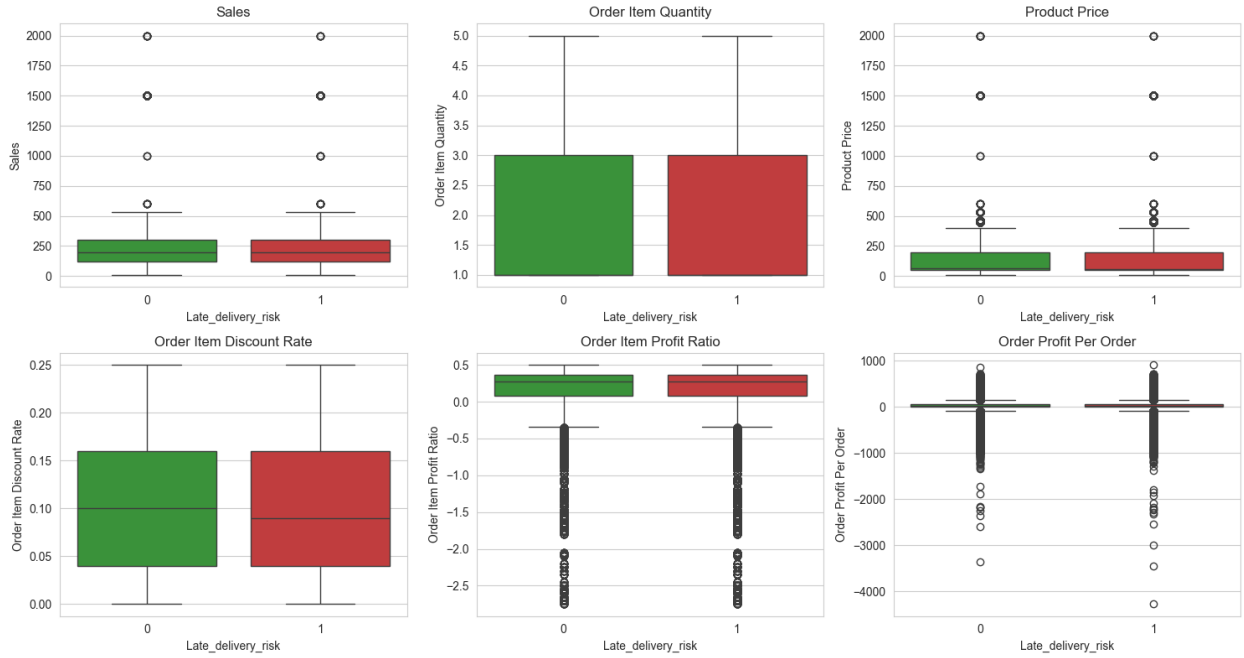
Hình 11: Tỉ lệ giao trễ theo Customer Segment và Type (hình thức thanh toán). *(nguồn: figures/fig12_late_by_customer_type.png)*

- Department và Category: hầu hết nằm trong khoảng 54–57%. Pet Shop cao nhất (58,9%) nhưng chỉ có 492 dòng.
- Customer Segment: Consumer 54,8%, Corporate 54,7%, Home Office 55,1%, nên không khác biệt.
- Type: TRANSFER thấp hơn rõ rệt (48,5%) so với CASH/DEBIT/PAYMENT (56,6–57,5%). Nguyên nhân là toàn bộ đơn CANCELED và SUSPECTED_FRAUD (luôn có nhãn "không trễ") đều có Type = TRANSFER (đã kiểm tra bằng crosstab Type × Order Status trong notebook). Type vẫn được giữ vì biết được ngay lúc đặt hàng, nhưng cần lưu ý đây là tín hiệu gián tiếp.

5.4 Biến số và tương quan



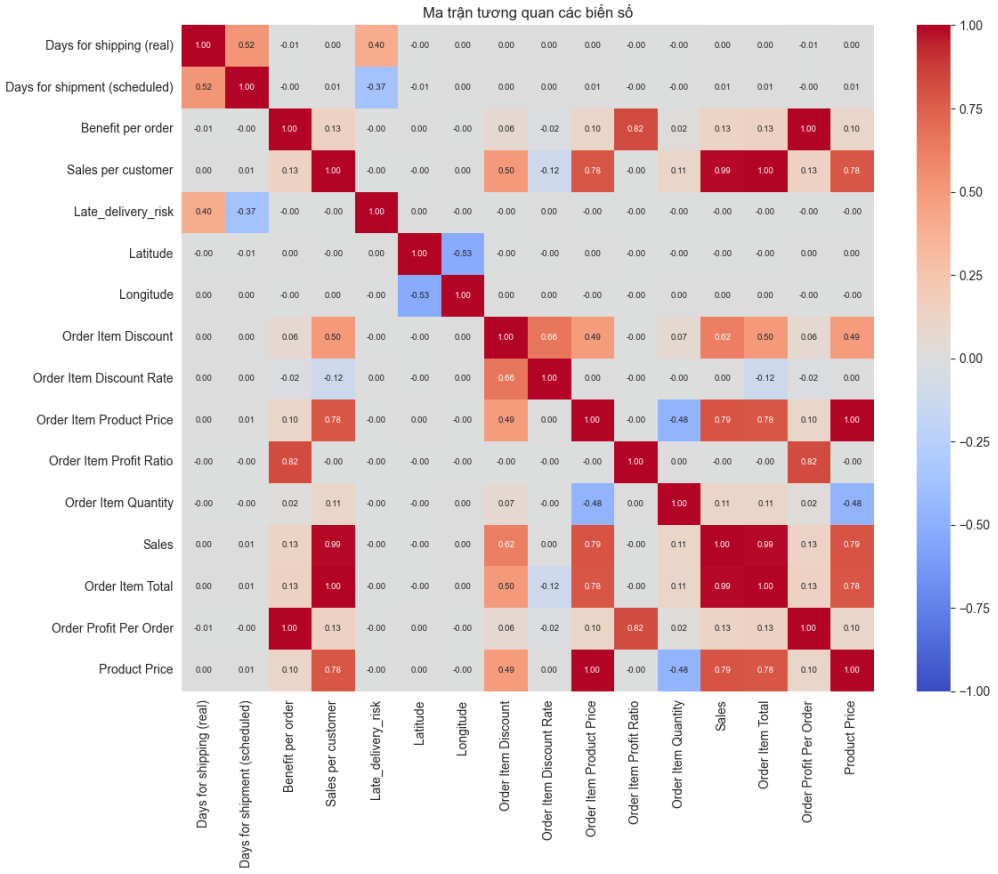
Hình 12: Phân phối (KDE) các biến số theo target. *(nguồn: figures/fig13_numeric_kde.png)*



Hình 13: Boxplot các biến số theo target. *(nguồn: figures/fig14_numeric_boxplot.png)*

Bảng 4: Giá trị trung bình của các biến số theo nhóm

Biến	TB nhóm không trễ	TB nhóm trễ
Sales	204,29	203,34
Order Item Quantity	2,128	2,127
Product Price	141,57	140,96
Order Item Discount Rate	0,1016	0,1017
Order Item Profit Ratio	0,1218	0,1197
Order Profit Per Order	22,40	21,62



Hình 14: Ma trận tương quan giữa các biến số. *(nguồn: figures/fig15_correlation.png)*

- Phân phối các biến tiền, giá và số lượng gần như trùng nhau giữa hai nhóm, nên các biến này ảnh hưởng rất yếu đến việc trễ.
- Order Profit Per Order có outlier âm lớn (min = $-4.274{,}98$), cần lưu ý khi dùng mô hình tuyến tính.
- Tương quan với target: Days for shipping (real) = $+0{,}40$ (leakage), Days for shipment (scheduled) = $-0{,}37$; tất cả các biến số khác có $|r| < 0{,}004$.
- Nhóm Sales / Order Item Total / Sales per customer tương quan rất cao với nhau $\rightarrow$ chỉ giữ Sales.

Tóm tắt EDA: yếu tố quyết định chính là **phương thức vận chuyển** (Shipping Mode / số ngày dự kiến). Các yếu tố địa lý, sản phẩm, khách hàng và giá trị đơn hàng chỉ ảnh hưởng yếu.

6. Tiền xử lý dữ liệu

Từ 53 cột ban đầu, loại bỏ **35 cột** theo các nhóm lý do sau (nguồn: results/cac_cot_bi_bo.csv):

Bảng 5: Các cột bị loại bỏ

Lý do	Số cột	Các cột
Leakage	4	Delivery Status, Days for shipping (real), shipping date (DateOrders), Order Status
Định danh / cá nhân	17	Customer Email, Customer Password, Customer Fname, Customer Lname, Customer Street, Customer Zipcode, Customer Id, Order Customer Id, Order Id, Order Item Id, Product Image, Product Name, Product Card Id, Order Item Cardprod Id, Category Id, Product Category Id, Department Id
Missing nhiều / 1 giá trị	3	Product Description, Order Zipcode, Product Status
Trùng lặp	5	Benefit per order, Sales per customer, Order Item Total, Order Item Product Price, Order Item Discount
Quá nhiều giá trị	6	Customer City, Customer State, Order City, Order State, Order Country, Customer Country

Các cột còn lại (17 cột + target): Type, Days for shipment (scheduled), Category Name, Customer Segment, Department Name, Latitude, Longitude, Market, order date (DateOrders), Order Item Discount Rate, Order Item Profit Ratio, Order Item Quantity, Sales, Order Profit Per Order, Order Region, Product Price, Shipping Mode.

Mã hóa: One-hot encoding (drop_first=True) cho 7 cột chữ (Type 4, Category Name 50, Customer Segment 3, Department Name 11, Market 5, Order Region 23, Shipping Mode 4 giá trị); cột order date (DateOrders) được giữ nguyên dạng ngày tháng. Kết quả: bảng dữ liệu **180.519 dòng** $\times$ **104 cột**. Không còn giá trị thiếu.

7. Kết luận, hạn chế và hướng phát triển

Kết luận Submission 1

- Xác định bài toán là **Binary Classification** với target Late_delivery_risk (54,8% / 45,2%, khá cân bằng).
- Phát hiện và loại bỏ **4 cột leakage**; chỉ riêng luật "số ngày giao thực tế $>$ số ngày dự kiến" đã khớp 97,55% với target.
- EDA cho thấy **Shipping Mode / số ngày giao dự kiến** là yếu tố quan trọng nhất; các yếu tố địa lý, sản phẩm, khách hàng và giá trị đơn hàng ảnh hưởng yếu.
- Tiền xử lý: loại 35 cột, one-hot encoding cho 7 cột chữ, dữ liệu không còn giá trị thiếu.

Hạn chế

- Chưa phân tích yếu tố thời gian (ngày/giờ đặt hàng).
- Tạm bỏ các cột nhiều giá trị (Order Country, Order City, Order State), có thể làm mất thông tin.

Hướng phát triển

- Nghiên cứu EDA theo thời gian (ngày/giờ đặt hàng).

- Target encoding hoặc frequency encoding cho Order Country, Order City.
- Xây dựng mô hình (đang thử nghiệm, chưa chốt).
- Mở rộng sang Multiclass với Delivery Status (4 lớp).

Phụ lục: Danh sách file minh chứng

Tất cả nội dung trong báo cáo đều có thể kiểm tra lại từ các file sau (đường dẫn tính từ thư mục gốc của project):

File	Nội dung	Mục
DataCo_Submission1.ipynb	Notebook đầy đủ code và output	Tất cả
DataCo_Submission1.html	Bản HTML của notebook	Tất cả
report/BaoCao_Submission1.tex	Mã nguồn LaTeX của báo cáo này	–
results/cac_cot_bi_bo.csv	Danh sách 35 cột bị loại kèm lý do	6
figures/fig01_missing.png	Giá trị thiếu	3.1
figures/fig02_target.png	Phân bố target	2
figures/fig03_leak_delivery_status.png	Leakage: Delivery Status	4
figures/fig04_leak_real_vs_scheduled.png	Leakage: ngày thực tế / dự kiến	4
figures/fig05_late_by_shipping_mode.png	Trễ theo Shipping Mode	5.1
figures/fig06_late_by_scheduled_days.png	Trễ theo số ngày dự kiến	5.1
figures/fig07_shipping_mode_vs_scheduled.png	Shipping Mode × số ngày dự kiến	5.1
figures/fig08_late_by_market.png	Trễ theo Market	5.2
figures/fig09_late_by_region.png	Trễ theo Order Region	5.2
figures/fig10_store_location.png	Vị trí cửa hàng	5.2
figures/fig11_late_by_product.png	Department / Category	5.3
figures/fig12_late_by_customer_type.png	Segment / Type	5.3
figures/fig13_numeric_kde.png	KDE biến số	5.4
figures/fig14_numeric_boxplot.png	Boxplot biến số	5.4
figures/fig15_correlation.png	Ma trận tương quan	5.4

Cách chạy lại: mở DataCo_Submission1.ipynb bằng Jupyter (Python có pandas, matplotlib, seaborn), đặt file DataCoSupplyChainDataset.csv cùng thư mục rồi chọn *Run All* (khoảng 1 phút). Thư mục figures/ và results/ sẽ được tạo tự động. Biên dịch báo cáo: vào thư mục report/ và chạy lệnh xelatex BaoCao_Submission1.tex (hoặc tectonic BaoCao_Submission1.tex).