DataCo Smart Supply Chain –
Dự đoán rủi ro giao hàng trễ

Mục lục

1 Tóm tắt kết quả **2**

2 Xử lý nhận xét của mentor **2**

3 Làm sạch dữ liệu **2**

4 EDA cập nhật trên dữ liệu sạch **3**

5 EDA theo thời gian **4**

5.1 Giờ đặt hàng 4

5.2 Tháng và thứ 4

5.3 Thay đổi từ 10/2017 5

6 Thiết kế đánh giá **5**

7 Baseline **6**

8 Mô hình **6**

9 Đã làm và chưa làm **8**

10 Hạn chế và hướng tiếp theo **8**

Phụ lục: Danh sách file minh chứng **9**

1. Tóm tắt kết quả

Báo cáo này trình bày tiến độ từ Submission 1 đến Submission 2 của bài toán **binary classification** với target Late_delivery_risk. Trọng tâm là xử lý 5 nhận xét của mentor, đặt baseline và kiểm tra xem mô hình có tốt hơn baseline hay không.

- **Làm sạch:** bỏ 7.754 dòng đơn hủy, còn 172.765 dòng và 62.897 đơn. Tỉ lệ trễ là 57,29% ở mức dòng và 57,31% ở mức đơn.
- **Phát hiện chính:** giờ đặt hàng chỉ có tác dụng trong Same Day: đơn đặt trước 12h trễ 0%, đơn đặt từ 12h trễ 100%.
- **Baseline:** trên tập test ở mức đơn, chỉ dùng Shipping Mode đạt accuracy 0,6984; thêm quy tắc 12h của Same Day đạt 0,7242.
- **Mô hình:** không mô hình nào vượt baseline 2. Logistic Regression có feature tương tác đạt 0,7242 và Decision Tree đạt 0,7238.

Kết luận: với các feature hiện có, mô hình chỉ học lại quy tắc Shipping Mode + 12h, chưa tạo thêm giá trị so với baseline 2. Kết quả chỉ áp dụng cho đơn không bị hủy.

2. Xử lý nhận xét của mentor

Bảng 1: 5 nhận xét của mentor và cách xử lý

Nhận xét	Việc đã làm và kết quả	Minh chứng
1. Bỏ các đơn Shipping canceled	Bỏ 7.754 dòng, tương ứng 2.855 đơn. Không có đơn hủy một phần. Luật real > scheduled khớp nhãn 100%.	Notebook mục 4b
2. Không chia ngẫu nhiên theo dòng	Đánh giá ở mức đơn, mỗi đơn 1 dòng. Dùng assert để xác nhận không có Order Id nào ở cả train và test.	Notebook mục 9b
3. Đặt baseline chỉ dùng Shipping Mode	Baseline 1 đạt 0,6984 trên test. Ở mức dòng, trên toàn bộ dữ liệu sạch đạt 0,6973, gần mức ∼69,5% của mentor. Thêm baseline 2 với quy tắc 12h.	Notebook mục 9b
4. Tách order date và làm EDA thời gian	Tách tháng, thứ, giờ. Phân tích ở mức đơn, có 3 biểu đồ mới.	Notebook mục 8b
5. Sửa lý do loại Customer Country	Tỉ lệ trễ 57,30% (EE. UU.) và 57,27% (Puerto Rico). Lý do mới: tỉ lệ trễ gần như bằng nhau giữa 2 nước.	Notebook mục 9

3. Làm sạch dữ liệu

Đơn hủy mang nhãn Late_delivery_risk = 0, giống đơn giao đúng hoặc trước hạn. Nhưng các đơn này chưa từng được giao, nên nhãn 0 không có nghĩa là “không trễ”.

Trước khi lọc, bài đã kiểm tra theo Order Id: mỗi đơn chỉ có 1 nhãn và 1 trạng thái. Vì vậy, lọc đơn hủy sẽ bỏ nguyên cả đơn, và việc gộp mỗi đơn còn 1 dòng không gây mâu thuẫn nhãn.

Bảng 2: Dữ liệu trước và sau khi bỏ đơn hủy

Chỉ số	Trước	Sau
Số dòng	180.519	172.765
Số đơn	65.752	62.897
Tỉ lệ trễ (mức dòng)	54,83%	57,29%
Luật real > scheduled khớp nhãn	97,55%	100%

Hệ quả: mô hình chỉ có giá trị với đơn không bị hủy. Lúc đặt hàng chưa biết đơn nào sẽ bị hủy, nên kết quả không áp dụng được cho những đơn sau đó bị hủy.

Trong tiền xử lý, Order Id được giữ lại chỉ để chia dữ liệu, không làm feature. Mục 9 của notebook bỏ 34 cột và giữ lại 19 cột.

4. EDA cập nhật trên dữ liệu sạch

Các số trong mục này tính ở mức dòng, sau khi bỏ đơn hủy.

Bảng 3: Tỉ lệ trễ và số ngày giao theo Shipping Mode

Shipping Mode	Số dòng	Ngày hẹn	Ngày thực tế	Tỉ lệ trễ
First Class	26.513	1	luôn là 2	100%
Second Class	33.806	2	2 đến 6	79,83%
Same Day	9.293	0	0 hoặc 1	47,93%
Standard Class	103.153	4	2 đến 6	39,77%



Hình 1: Tỉ lệ trễ theo Shipping Mode sau khi bỏ đơn hủy *(nguồn: figures_s2/fig05_late_by_shipping_mode.png)*

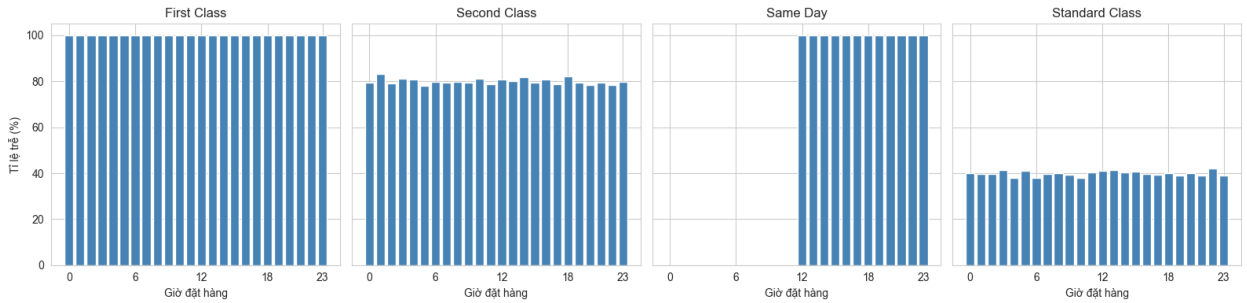
- Shipping Mode vẫn là yếu tố mạnh nhất. Mỗi mode gắn với đúng 1 giá trị Days for shipment (scheduled), nên hai cột này trùng thông tin.
- Type = TRANSFER còn 57,48%, không còn thấp hơn các loại khác (56,63% đến 57,53%). Khác biệt ∼48,5% trước đây là do nhóm này chứa toàn bộ đơn hủy.
- Market chỉ từ 56,84% đến 57,69%, nên ảnh hưởng yếu. Order Region từ 51,60% (Canada, 907 dòng) đến 60,15% (Central Africa, 1.616 dòng), nhưng hai nhóm ở hai đầu đều ít dòng nên chưa đủ để kết

luận.

5. EDA theo thời gian

Mục này phân tích ở mức đơn, vì các dòng trong cùng đơn có chung giờ đặt và chung nhãn. Tỉ lệ trễ ở mức đơn là 57,31%.

5.1 Giờ đặt hàng



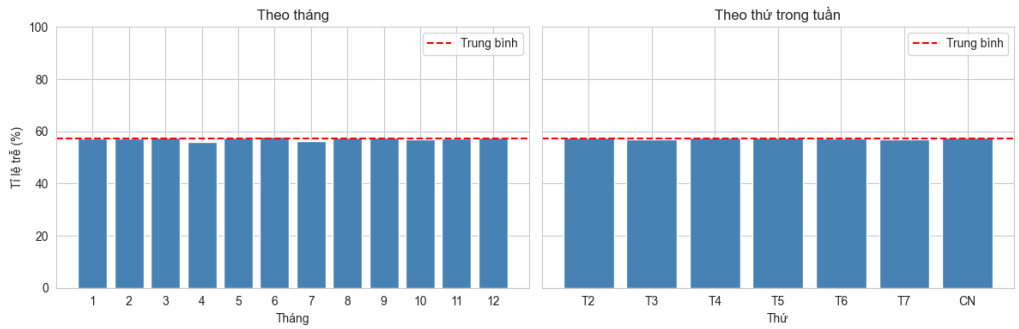
Hình 2: Tỉ lệ trễ theo giờ đặt hàng, tách theo Shipping Mode *(nguồn: figures_s2/fig16_gio_theo_shipping_mode.png)*

Bảng 4: Tỉ lệ trễ trước 12h và từ 12h, ở mức đơn

Shipping Mode	Trước 12h	Từ 12h
First Class	100%	100%
Second Class	80,01%	79,96%
Same Day	0% (1.759 đơn)	100% (1.648 đơn)
Standard Class	39,60%	40,10%

Giờ đặt hàng chỉ có tác dụng trong Same Day, với mốc chốt 12h. Đây là tương tác giữa hai cột. Nhận định trước đây rằng feature giờ không đáng tin được sửa lại như sau: giờ có tác dụng trong Same Day, còn các mode khác thì không.

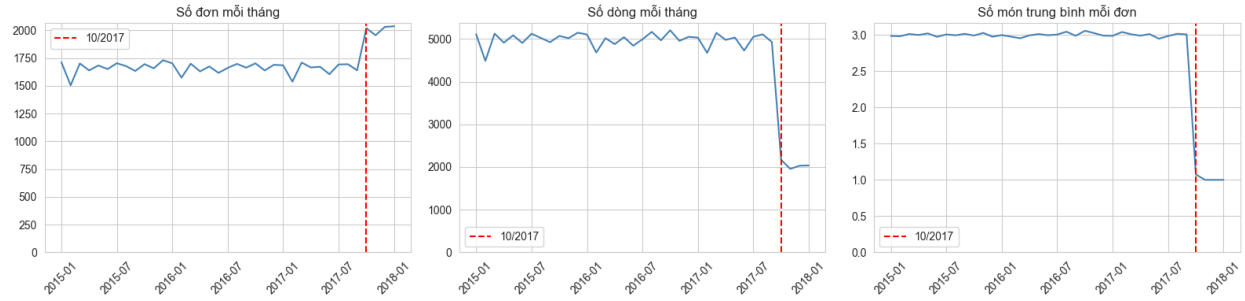
5.2 Tháng và thứ



Hình 3: Tỉ lệ trễ theo tháng và thứ trong tuần *(nguồn: figures_s2/fig17_thang_va_thu.png)*

Tỉ lệ trễ gần như phẳng theo tháng (56,11% đến 57,87%) và theo thứ (56,90% đến 57,64%).

5.3 Thay đổi từ 10/2017



Hình 4: Số đơn, số dòng và số món mỗi đơn theo tháng *(nguồn: figures_s2/fig18_thay_doi_tu_10_2017.png)*

Nhận định trước đây chỉ nói số dòng giảm từ 10/2017. Phân tích mới cho thấy từ 10/2017 số món mỗi đơn gần như chỉ còn 1, còn số đơn mỗi tháng thực ra tăng:

- Số món trung bình mỗi đơn giảm từ 3,00 xuống 1,02, và 99,23% đơn chỉ có 1 món.
- Từ tháng 9 sang tháng 10/2017, số dòng giảm từ 4.931 xuống 2.169, còn số đơn tăng từ 1.640 lên 2.019.
- Tỉ lệ trễ gần như không đổi: 57,26% trước và 57,64% từ 10/2017.

6. Thiết kế đánh giá

- **Mức đánh giá:** mức đơn, mỗi đơn 1 dòng. Nhãn và các feature đã chọn đều là thông tin của cả đơn. Nếu đánh giá ở mức dòng, đơn nhiều món sẽ có trọng số lớn hơn.
- **Cách chia:** train_test_split, 80% train (50.317 đơn) và 20% test (12.580 đơn). Vì mỗi đơn chỉ có 1 dòng nên một đơn không thể nằm ở cả hai tập.
- **stratify:** giữ tỉ lệ trễ của hai tập bằng nhau, đều 57,31%.
- **random_state=42:** cố định trước khi xem kết quả để tái lập được kết quả. Giá trị 42 không có ý nghĩa riêng.
- **Chỉ số:** accuracy, precision, recall, F1 và ROC-AUC, với lớp dương là "trễ".

Vì sao chọn test_size=0.2? Với accuracy khoảng 0,72, sai số ước tính như sau:

Bảng 5: Sai số ước tính của accuracy theo kích thước tập test

test_size	Số đơn test	Số đơn train	Khoảng 95%
0,1	6.290	56.607	±1,10 điểm
0,2	12.580	50.317	±0,78 điểm
0,3	18.870	44.027	±0,64 điểm

Tỉ lệ 20% giữ được phần lớn dữ liệu để học, trong khi sai số ở mức chấp nhận được và phù hợp với mức dao động đo được ở mục 7.

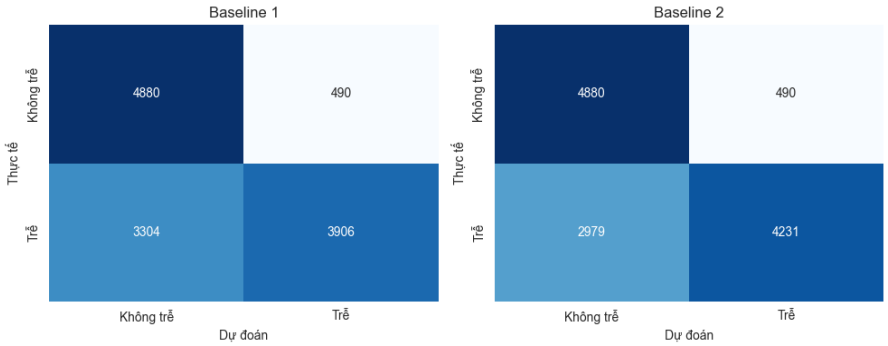
7. Baseline

Có 3 mốc so sánh. Mọi quy tắc đều được học trên train rồi mới áp lên test.

- **Luôn đoán trễ:** mốc thấp nhất.
- **Baseline 1:** đoán theo lớp đa số của từng mode trên train. First Class và Second Class đoán trễ; Same Day và Standard Class đoán không trễ.
- **Baseline 2:** giống baseline 1, riêng Same Day đoán theo giờ đặt. Trên riêng tập train, quy tắc vẫn đúng: trước 12h trễ 0% (1.384 đơn), từ 12h trễ 100% (1.323 đơn).

Bảng 6: Kết quả baseline trên tập test, mức đơn, random_state=42

Cách làm	Accuracy	Precision	Recall	F1
Luôn đoán trễ	0,5731	0,5731	1,0000	0,7287
Baseline 1	0,6984	0,8885	0,5417	0,6731
Baseline 2	0,7242	0,8962	0,5868	0,7092



Hình 5: Confusion matrix của 2 baseline trên tập test *(nguồn: figures_s2/fig19_confusion_baseline.png)*

- Thêm một quy tắc cho Same Day làm accuracy tăng khoảng 2,6 điểm.
- **Luôn đoán trễ** có F1 cao nhất dù accuracy thấp nhất, vì nó bắt được mọi đơn trễ. Vì vậy không nên chỉ nhìn F1.
- Toàn bộ lỗi của baseline 2 nằm ở 2 mode: 2.979 đơn Standard Class trễ nhưng bị đoán không trễ, và 490 đơn Second Class không trễ nhưng bị đoán trễ.
- Qua 5 cách chia, baseline 1 dao động từ 0,6921 đến 0,6998, baseline 2 từ 0,7178 đến 0,7250. Lần chia với giá trị 42 nằm ở phía cao của khoảng này, nên báo cáo nêu cả khoảng dao động.

8. Mô hình

Feature: Shipping Mode, hour, dow, month, Market, Order Region, Type, Customer Segment; tổng cộng 42 feature sau one-hot.

Không dùng: 4 cột leakage, Order Id, nhóm sản phẩm (thông tin của từng món, 63,1% đơn có nhiều hơn 1 Department Name) và Days for shipment (scheduled) (trùng với Shipping Mode).

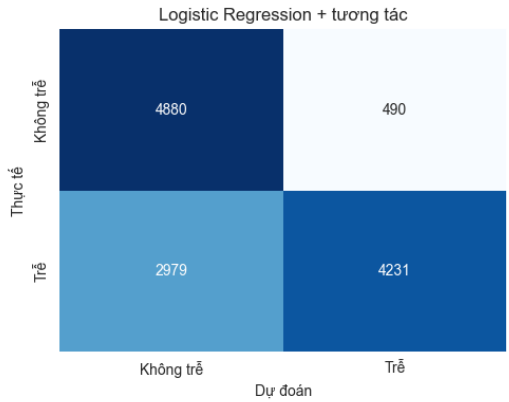
Tham số được đặt trước và không chỉnh theo tập test.

Bảng 7: So sánh mô hình với baseline 2 trên tập test, mức đơn, random_state=42

Cách làm	Accuracy	Precision	Recall	F1	ROC-AUC	Acc. train
Baseline 2	0,7242	0,8962	0,5868	0,7092	–	–
Logistic Regression	0,7177	0,8934	0,5763	0,7006	0,7435	0,7163
Logistic Regression + tương tác	0,7242	0,8962	0,5868	0,7092	0,7778	0,7222
Decision Tree (max_depth=6)	0,7238	0,8931	0,5885	0,7095	0,7777	0,7227

Bảng 8: Accuracy trên 5 cách chia

Cách làm	0	1	2	3	42	Trung bình
Baseline 2	0,7178	0,7250	0,7240	0,7210	0,7242	0,7224
Logistic Regression	0,7115	0,7196	0,7140	0,7119	0,7177	0,7149
Logistic Regression + tương tác	0,7178	0,7250	0,7240	0,7210	0,7242	0,7224
Decision Tree (max_depth=6)	0,7167	0,7251	0,7229	0,7199	0,7238	0,7217



Hình 6: Confusion matrix của Logistic Regression + tương tác, giống hệt baseline 2 *(nguồn: figures_s2/fig20_confusion_mo_hinh.png)*

- Logistic Regression không tự học được tương tác "Same Day và từ 12h", nên thấp hơn baseline 2. Thêm feature tương tác thì accuracy bằng baseline 2 ở cả 5 cách chia.
- Decision Tree tự học được tương tác đó mà không cần tạo feature riêng.
- Decision Tree gần như chỉ dùng Shipping Mode và hour: Standard Class 0,6463, hour 0,1935, Same Day 0,1051, Second Class 0,0491. Các feature khác rất nhỏ.
- Accuracy train và test gần nhau nên không thấy overfit. Accuracy cao nhất là 0,7242, thấp hơn nhiều so với mức bất thường, nên chưa có dấu hiệu leakage.

Chênh lệch giữa baseline 2 và hai mô hình tốt nhất nằm trong mức dao động do cách chia, nên không kết luận được mô hình nào tốt hơn. Mô hình có ROC-AUC 0,778, nhưng baseline 2 không có chỉ số này để so sánh.

9. Đã làm và chưa làm

Bảng 9: Tiến độ Submission 2

Đã làm	Chưa làm
Xử lý 5 nhận xét của mentor	Chia train/test theo thời gian
Làm sạch dữ liệu và chạy lại EDA	Thử nhiều mô hình và tinh chỉnh tham số
EDA thời gian ở mức đơn	Tìm feature mới cho Second Class và Standard Class
Chia dữ liệu theo đơn, đặt 3 mốc so sánh	Viết blog và làm video
Train 3 mô hình đơn giản và so trên 5 cách chia	

10. Hạn chế và hướng tiếp theo

Hạn chế

- **Phạm vi:** kết quả chỉ áp dụng cho đơn không bị hủy.
- **Dữ liệu có dấu hiệu mô phỏng:** First Class luôn giao sau 2 ngày, Same Day có mốc chốt đúng 12h, còn Second Class và Standard Class có số ngày thực tế phân bố gần đều từ 2 đến 6. Đây là suy luận từ số liệu, không phải khẳng định về logistics ngoài đời.
- **Cấu trúc đơn đổi từ 10/2017:** nếu chia theo thời gian, tập test sẽ nằm trong giai đoạn có cấu trúc đơn khác.
- **Quy tắc 12h được phát hiện khi xem toàn bộ dữ liệu**, kể cả phần sau này là tập test. Quy tắc đã được kiểm tra lại trên riêng tập train và vẫn đúng.
- **Baseline đã mạnh:** phần lỗi còn lại nằm ở Second Class và Standard Class, nơi các feature hiện có chưa phân biệt được nhãn.
- **Chưa kiểm tra chia theo thời gian**, nên chưa biết kết quả có giữ được khi dự đoán các đơn tương lai hay không.

Hướng tiếp theo

1. Chia theo thời gian để kiểm tra độ bền.
2. Tìm feature mới cho Second Class và Standard Class.
3. Chỉ thử mô hình phức tạp hơn nếu có feature mới mang thêm thông tin.

Phụ lục: Danh sách file minh chứng

File	Nội dung
DataCo_Submission2.ipynb	Notebook đã chạy kèm output
DataCo_Submission2.html	Bản HTML của notebook
figures_s2/	20 biểu đồ của Submission 2
results_s2/cac_cot_bi_bo.csv	Danh sách cột bị bỏ kèm lý do
results_s2/ket_qua_baseline.csv	Kết quả 3 mốc so sánh
results_s2/ket_qua_mo_hinh.csv	Kết quả baseline và mô hình
results_s2/so_sanh_5_cach_chia.csv	Accuracy trên 5 cách chia