Nhật ký học tập – Cập nhật đến 05/11/2026

DataCo Smart Supply Chain – Dự đoán rủi ro giao hàng trễ

Submission 2

1. Các việc cần làm

1. Lên kế hoạch xử lý 5 nhận xét của mentor và kiểm tra các số kỳ vọng trên dữ liệu thật.
2. Tạo notebook Submission 2 riêng để giữ nguyên minh chứng của Submission 1.
3. Tự viết code kiểm tra mỗi đơn có đúng 1 nhãn và 1 trạng thái.
4. Bỏ đơn hủy, chạy lại EDA, sửa các nhận xét đã cũ.
5. Làm EDA theo thời gian ở mức đơn.
6. Chia train/test ở mức đơn, đặt 3 mốc so sánh.
7. Train 3 mô hình đơn giản và so sánh trên 5 cách chia.
8. Viết báo cáo, cập nhật README và nhật ký.

2. Số quan trọng

Nội dung	Kết quả
Số dòng sau khi bỏ đơn hủy	172.765
Số đơn sau khi bỏ đơn hủy	62.897
Tỉ lệ trễ mức dòng / mức đơn	57,29% / 57,31%
Luật real > scheduled khớp nhãn	100%
Same Day trước 12h / từ 12h	0% / 100% trễ
Số món mỗi đơn trước / từ 10/2017	3,00 / 1,02
Luôn đoán trễ (accuracy test)	0,5731
Baseline 1: Shipping Mode	0,6984
Baseline 2: thêm quy tắc 12h	0,7242
Logistic Regression + tương tác	0,7242
Decision Tree (max_depth=6)	0,7238

3. Điều học được

- **Nhãn phải có nghĩa**: đơn hủy mang nhãn 0 giống đơn giao đúng hạn, nhưng thực ra chưa từng được giao. Bỏ các đơn này làm tỉ lệ trễ tăng từ 54,83% lên 57,29%.
- **Phạm vi mô hình**: sau khi bỏ đơn hủy, mô hình chỉ áp dụng cho đơn không bị hủy.
- **Chia theo nhóm**: các dòng trong cùng đơn có chung nhãn. Nếu chia theo dòng, một đơn có thể nằm ở cả train và test. Khi mỗi đơn chỉ còn 1 dòng thì không còn vấn đề này.

- **Mức đánh giá**: ở mức dòng, đơn nhiều món được tính nhiều lần. Ở mức đơn, mỗi đơn có trọng số bằng nhau.
- **Baseline**: là mốc so sánh đơn giản. Nó phải được học trên train rồi mới áp lên test.
- **Tương tác giữa các feature**: giờ đặt không có tác dụng rõ khi nhìn tổng thể, nhưng quyết định hoàn toàn nhãn trong Same Day. Logistic Regression cần feature riêng để học điều này, còn Decision Tree tự học được.
- **Dao động do cách chia**: chỉ đổi random_state, accuracy đã dao động khoảng 0,7 điểm. Vì vậy không được chọn random_state cho kết quả đẹp, và không nên kết luận từ chênh lệch nhỏ.
- **test_size và random_state**: 20% cân bằng giữa dữ liệu để học và độ ổn định khi đánh giá. Số 42 không có ý nghĩa riêng, điều quan trọng là cố định nó trước khi xem kết quả.
- **F1 có thể gây hiểu lầm**: "luôn đoán trễ" có F1 cao nhất dù accuracy thấp nhất.
- **Mô hình không vượt baseline cũng là kết quả**: bài cho thấy với feature hiện có, mô hình chỉ học lại quy tắc đơn giản.